의미·빈도 정보를 반영한 로그 복합 임베딩 기반 이상 탐지 기법*

김예은[01], 구본유[2], 한인성[3], 이정식[3], 박성진[4], 임선영[4], 오병국[2]
[1]건국대학교 스마트ICT융합공학과, [2]건국대학교 검퓨터공학과, [3]국방과학연구소,
[4]LIG Defence & Aerospace
katekim512@konkuk.ac.kr, bykoo@konkuk.ac.kr, p9741181@gmail.com, godsider@naver.com,
sungjin.park2@ligdna.com, sunyoung.im@ligdna.com, bkoh@konkuk.ac.kr

Semantic and Frequency-Aware Hybrid Log Embedding for Anomaly Detection

Yeeun Kim[01], Bonyou Koo[2], Insung Han[3], Jungsik Lee[3], Sung-Jin Park[4], Sun-Young Im[4],
Byungkook Oh[2]
[1]Smart ICT Convergence, Konkuk University
[2]Computer Science & Engineering, Konkuk University
[3] Agency for Defense Development
[4]LIG Defence & Aerospace

요 약

로그 기반 이상 탐지는 대규모 분산 시스템에서 발생하는 로그 데이터를 분석하여 비정상적인 패턴을 탐지하는 중요한 문제다. 그러나 기존의 로그 분석 방식은 로그 파서(Parser)를 통해 추출된 이벤트 템플릿만을 활용함으로써 로그 메시지 내부의 세부 파라미터 정보가 손실되는 한계를 지닌다. 또한, 로그 임베딩 과정에서 무작위 초기화 방식을 채택하여 로그 간의 의미적 관계를 충분히 반영하지 못하며, 로그 발생 빈도와 같은 양적 변화를 감지하는 데 어려움이 있다. 본 논문에서는 이러한 문제를 해결하기 위해 새로운 로그 임베딩 방식을 제안한다. 실험 결과, 제안된 방법의 임베딩을 활용한 모델은 기존 모델에 비해 우수한 성능을 보였으며, 의미 정보와 발생 빈도가 이상 탐지 능력을 효과적으로 향상시킴을 확인하였다.

1. 서 론

최근 대규모 분산 시스템에서 발생하는 방대한 로그 데이터를 분석하여 시스템의 결함을 감지하는 로그 기반 이상 탐지(Log-based Anomaly Detection) 기술은 시스템 안정성 확보를 위한 필수적인 요소로 자리 잡았다. 특히, LogBERT[1]와 같은 Transformer 기반 모델들은 로그 시퀀스의 양방향 문맥을 학습함으로써 기존 통계 기반 방식보다 정교한 이상 징후 포착 능력을 보여주고 있으나, 여전히 로그가 지닌 다양한 정보 요소를 충분히 반영하지 못한다는 한계가 존재한다.

구체적으로, 기존 방법은 Drain과 같은 파서를 통해 원시 로그(Raw Log)를 템플릿으로 변환한 후 시퀀스로 입력한다. 그러나 이 과정에서 로그 메시지 내부의 파라미터, 경로, 수치 등 세부 정보가 손실되며, 이벤트는 랜덤 임베딩으로 표현되어 의미적으로 유사한 로그 간의 관계를 반영하지 못한다. 또한, 이벤트의 순서 패턴에만 의존하기 때문에 특정 이벤트가 단시간 내에 비정상적으로 급증하는 로그 폭풍(Log Storm)과 같은 양적 이상 패턴을 포착하기 어렵다.

이를 해결하기 위해 본 연구는 세 가지 관점의 임베딩을 결합한 새로운 로그 임베딩 방식을 제안한다. 이벤트 템플릿의 거시적 의미, 원시 로그의 세부 의미, 그리고 로그 발생 빈도의 양적 변화를 각각 독립적으로 임베딩한 뒤 이를 결합함으로써 로그가 지닌 다양한 특징을 하나의 표현에 반영할 수 있다.

2. 관련 연구

2.1 로그 파싱

로그 데이터는 비정형 텍스트 형태로 생성되기 때문에, 이를 정형화하기 위한 로그 파싱이 필수적이었다. 대표적인 Drain은 정규표현식과 고정 깊이 트리를 활용하여 로그 메시지를 이벤트 템플릿으로 변환함으로써 이후 시퀀스 기반 분석이 가능하도록 하였다. 그러나 이러한 방식은 로그 메시지의 일부 정보를 제거하므로 로그의 세부 내용 파악이 어렵다. 이에 따라 최근에는 템플릿 단순 인덱싱을 넘어,

* 이 논문은 2026년 정부(방위사업청)의 재원으로 국방과학연구소의 지원을 받아 수행된 연구임(UG253005TD)

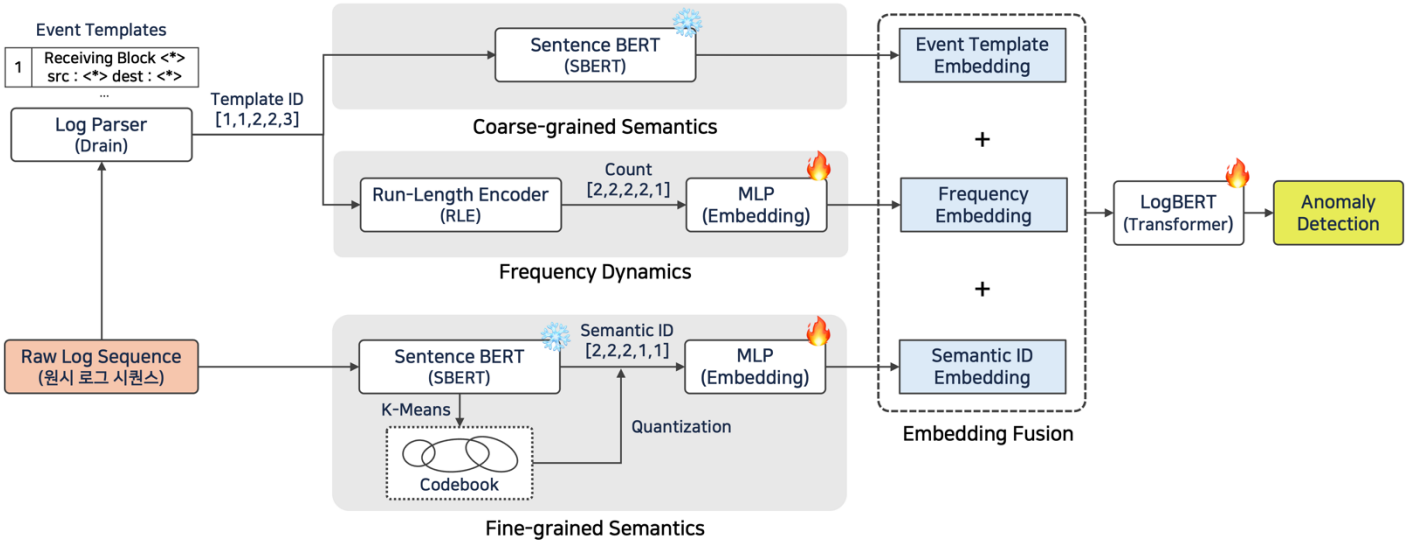


그림 1 : 로그의 의미, 빈도 임베딩을 결합한 LogBERT 기반 이상탐지 모델 프레임워크

로그가 내포한 의미 정보를 수치화하여 표현하려는 임베딩 기반 접근의 필요성이 제기되고 있다.

2.2 딥러닝 기반 이상 탐지

이후, 딥러닝 기반 접근이 등장하면서 로그 시퀀스로부터 정상 패턴을 학습하는 연구가 활발히 이루어졌다. DeepLog[2]는 LSTM 기반의 순환 신경망을 활용하여 로그의 순차적인 흐름을 학습하였으며, 이후 LogBERT[1]와 같이 Transformer 기반 모델이 도입되면서 긴 시퀀스 내의 로그 패턴을 파악할 수 있게 되었다. 하지만 이러한 모델들은 주로 로그 시퀀스의 '순차적 패턴' 학습에 국한되어 있어, 특정 이벤트가 단시간 내에 비정상적으로 급증하는 로그 폭풍과 같은 이상 징후를 식별하기 어렵다는 문제점이 있다. 따라서 본 연구에서는 시퀀스의 문맥 정보뿐만 아니라 RLE(Run-Length Encoding)을 통해 추출된 발생 빈도 정보를 모델에 주입함으로써 양적 변화도 고려할 수 있는 이상 탐지 모델을 제안하고자 한다.

3. 제안 방법

본 연구에서는 로그 데이터를 보다 풍부하게 표현하기 위해 세 가지 관점에서 임베딩을 구성하고 이를 결합하는 방법을 제안한다. 제안 방법은 그림 1과 같이, 이벤트 템플릿의 거시적 의미를 포착하는 Coarse-grained Semantics, 로그 발생 빈도의 양적 변화를 반영하는 Frequency Dynamics, 원시 로그의 세부 의미를 보존하는 Fine-grained Semantics의 세 관점으로 구성된다. 각 관점에서 생성된 Event Template Embedding, Frequency Embedding, Semantic ID Embedding은 Embedding Fusion 과정을 통해 단일 벡터로 결합되어 LogBERT에 입력된다.

3.1 Semantic ID Embedding

기존 방법은 파서를 통해 추출된 템플릿만을 활용하기 때문에, 로그 메시지의 세부적인 표현이 손실되는 문제가 있다. 이를 보완하기 위해, 원시 로그 내부에 포함된 세밀한 상태 변화를 포착할 수 있는 Fine-grained Semantics 관점의 Semantic ID Embedding을 제안한다. 원시 로그 텍스트 전체를 Sentence-BERT(SBERT)[3]를 이용하여 고차원 벡터로 인코딩한 후, 계층적 잔차 양자화(Residual Quantization)를 적용하여 이산화된 Semantic ID를 생성한다. 이 과정에서 각 단계별 코드북(Codebook)은 로그의 의미 공간을 대표하는 기준 벡터들을 보유하며, 입력 벡터와의 유클리드 거리가 가장 가까운 코드북 인덱스를 순차적으로 할당한다. 생성된 Semantic ID는 MLP를 통해 학습 가능한 임베딩 벡터로 변환되며, 이를 통해 기존 파서가 일부 파라미터를 제거함으로써 상실했던 세부 정보들을 벡터 공간에 보존할 수 있다.

3.2 Event Template Embedding

Codebook 기반 Semantic ID Embedding은 국소적인 의미 구분에 초점을 둔다면, Event Template Embedding은 로그 시퀀스의 거시적인 의미 흐름을 파악한다. 본 연구에서는 Parser를 통해 추출된 이벤트 템플릿을 Sentence-BERT로 임베딩하여 v_s을 생성한다. 이는 기존의 무작위 초기화 방식과 달리, 유사한 의미를 지닌 템플릿 간의 의미적 상관관계를 수치화할 수 있다. 결과적으로 로그 시퀀스의 거시적인 흐름과 문맥적 의미를 파악하며, 유사한 기능을 수행하는 템플릿 간의 연관성을 LogBERT에 전달할 수 있다.

3.3 Frequency Embedding

로그의 발생 빈도와 같은 양적 변화를 학습에 반영하기 위해 RLE를 적용하여 동일 이벤트의 연속 발생 횟수를 추출한다. 예를 들어, 시퀀스 [1,1,2,2,3] 는 빈도 시퀀스 [2,2,2,2,1] 로 변환된다. 추출된 빈도 값은 MLP(Multi-Layer Perceptron)를 통해 학습 가능한 벡터 v_f 로 변환되며, 이는 로그의 양적 패턴을 반영하는 표현으로 사용된다.

3.4 임베딩 결합

3.1-3.3에서 생성된 세 가지 임베딩 (v_s, v_e, v_f) 을 하나로 통합한다. 각 임베딩은 동일한 차원으로 구성되어 원소별 덧셈(Element-wise Addition) 방식을 통해 결합되며, 이를 통해 차원의 팽창 없이 서로 다른 관점의 정보를 단일 벡터 내에 중첩시킨다.

4. 실험

4.1 데이터셋 및 평가방법

본 연구에서는 로그 이상 탐지 벤치마크 데이터셋인 HDFS, BGL, Tbird[4]를 사용하여 실험을 수행하였다. 3절에서 설명한 방법에 따라 임베딩을 생성하여 LogBERT에 입력하여 이상탐지를 실시하였다. 모델의 성능 평가는 이상 탐지 문제에서 널리 사용되는 F1-score를 기준으로 수행한다. 비교 실험에서는 랜덤 임베딩을 이용한 기존 LogBERT를 baseline으로 사용하였다.

Method	Dataset		
	HDFS	**BGL**	**TBird**
LogBERT + rand (Baseline)	73.531	40.997	87.79
LogBERT + v_f	74.797	55.393	87.733
LogBERT + v_e	**79.223**	60.077	87.883
LogBERT + $v_e + v_f$	75.04	60.257	88.647
LogBERT + $v_s + v_e + v_f$ (Proposed)	77.037	**61.797**	**90.393**

표 1. 데이터셋별 탐지 성능 (F1-score)

4.2 실험 결과 및 분석

표 1의 결과를 통해 확인할 수 있듯이, 본 연구에서 제안한 로그 임베딩 방법은 기존 템플릿 기반 형식에 비해 이상 탐지 성능을 유의미하게 향상 시켰다. 특히, 세 가지 임베딩을 모두 결합한 "LogBERT + $v_s + v_e + v_f$ " 방식은 BGL[4] 데이터셋에서 61.797, TBird[4] 데이터셋에서 90.393를 기록하며 가장 우수한 성능을 보였다. 특히 BGL[4] 데이터셋의 경우, 기존 랜덤 임베딩 방식 (40.997) 대비 약 20 이상의 성능 향상을 보였는데, 이는 로그의 의미 정보와 양적 변화를 동시에 고려하는 전략이 모델의 정밀한 이상 탐지를 효과적으로 유도했음을 나타낸다.

개별 임베딩의 기여도를 살펴보면 Frequency Embedding(v_f)을 추가했을 때 BGL[4] 데이터셋에서 약 14.4의 성능 향상이 관찰되었다. 이는 로그 폭풍(Log Storm)이 빈번한 BGL[4] 데이터셋과 같은 환경에서 빈도 임베딩이 효과적일 수 있음을 의미한다. 또한, 원시 로그의 세부 의미를 보존하는 SemanticID Embedding(v_s)을 최종적으로 결합했을 때 대부분의 데이터셋에서 최상위 성능을 기록하였다. 이는 기존 파서에 의해 제거되던 세부 정보를 효과적으로 활용하고, 이를 학습에 반영한 것이 모델의 식별력을 높이는 데 기여하였음을 알 수 있다.

반면, HDFS[4] 데이터셋의 경우 Event Template Embedding만을 활용하는 방식이 79.223로 가장 높은 수치를 기록하였다. BGL[4]과 TBird[4] 데이터셋의 템플릿 개수가 19,179개와 863개인 것과 달리, HDFS[4] 데이터셋은 11,175,629개의 로그를 포함함에도 템플릿 개수가 20개에 불과한 것으로 보아, 소수의 이벤트 템플릿이 반복적으로 등장하는 매우 정형화된 구조임을 알 수 있다. 이에 따라 이벤트 ID 기반의 템플릿 표현만으로도 정상 패턴을 충분히 학습할 수 있으며, 원시 로그 의미 정보나 빈도 정보의 추가 효과가 BGL[4] 및 TBird[4]에 비해 제한적으로 나타난 것으로 판단된다.

5. 결론

본 연구는 로그의 의미 정보와 반복 패턴을 동시에 반영하기 위해 Semantic ID Vector, Event Template Vector, Frequency Vector를 결합한 임베딩 방식을 제안한다. 제안 방식은 원시 로그 기반 Semantic ID로 로그의 세부 의미를 반영하고, 이벤트 템플릿 기반 Semantic Vector로 로그의 거시적 흐름을 파악하며, 이벤트 발생 빈도를 반영한 Frequency Vector을 통해 양적 정보를 학습할 수 있도록 하였다. 실험 결과, 제안 방법은 기존 모델 대비 이상 탐지 성능을 향상시켰으며, 특히 Log Storm과 같은 이상 상황에서 보다 안정적인 탐지 성능을 보였다. 이를 통해 로그 데이터를 단순 시퀀스가 아닌 의미와 패턴이 결합된 표현으로 재구성하는 것이 효과적임을 확인하였다. 향후 데이터셋의 특성을 반영하여 각 임베딩의 기여도를 동적으로 조절하는 방식을 통해 다양한 로그 환경으로 확장할 수 있을 것으로 기대하며, 실제 환경에 대한 검증을 통해 일반화 성능을 분석할 필요가 있다.

6. 참고문헌

[1] Haixuan Guo, Shuhan Yuan, and Xintao Wu. "LogBERT : Log Anomaly Detection via BERT ", 2021

[2] Min Du, Feifei Li, Guineng Zheng, and Vivek Srikumar. "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning." Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS), pp. 1285-1298 , 2017.

[3] Nils Reimers and Iryna Gurevych. "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks." Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 3982-3992, 2019.

[4] HDFS, BGL, Tbird Dataset
https://github.com/logpai/loghub